

Session 12

PCA

Principal component analysis

Machine Learning | Zahra Amini

Telegram: @zahraamini_ai & Instagram: @zahraamini_ai & LinkedIn: @zahraamini-ai

<https://zil.ink/zahraamini>

گاهش بعد یا تقلیل ابعاد ← مقدمات ماتریس ها:

$$A = \begin{bmatrix} a_{11} & 0 & 0 \\ 0 & a_{22} & 0 \\ 0 & 0 & a_{33} \end{bmatrix}$$

ماتریس قطری: ماتریسی که تمام درایه هایش به جز درایه های قطر اصلی، صفر هستند.

$$I = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}_{2 \times 2}$$

ماتریس همانی یا یکه (I): ماتریس مربعی که تمام درایه هایش صفر هستند به جز درایه های قطر اصلی اش که 1 هست.

$$A^T A = A A^T = I$$

ماتریس متعامد (orthogonal): ماتریس مربعی است که:

$$A = \begin{bmatrix} 1 & 0 & 0 \\ 0 & \frac{3}{5} & -\frac{4}{5} \\ 0 & \frac{4}{5} & \frac{3}{5} \end{bmatrix} \quad A^T = \begin{bmatrix} 1 & 0 & 0 \\ 0 & \frac{3}{5} & \frac{4}{5} \\ 0 & -\frac{4}{5} & \frac{3}{5} \end{bmatrix} \quad A A^T = \begin{bmatrix} (1 \times 1 + 0 + 0) & 0 & 0 \\ 0 & (0 + \frac{9}{25} + \frac{16}{25}) & 0 \\ 0 & 0 & 1 \end{bmatrix}$$

$$A = \begin{bmatrix} a & b \\ c & d \end{bmatrix} \quad |A| = \begin{vmatrix} a & b \\ c & d \end{vmatrix} = ad - bc$$

دترمینان ماتریس:

$$\text{ex: } A = \begin{bmatrix} 4 & 1 \\ 1 & 2 \end{bmatrix} \rightarrow |A| = (4 \times 2) - (1 \times 1) = 7$$

ex: $A = \begin{bmatrix} -1 & 4 & 3 \\ 2 & 6 & 4 \\ 3 & -2 & 8 \end{bmatrix} \rightarrow |A| = ?$

$$|A| = \begin{vmatrix} -1 & 4 & 3 \\ 2 & 6 & 4 \\ 3 & -2 & 8 \end{vmatrix} = -1(6 \times 8 - (4 \times (-2))) - 4(2 \times 8 - 4 \times 3) + 3(2 \times (-2) - 3 \times 6) = -138$$

بردار ویژه و مقدار ویژه ی یک ماتریس:

$A \cdot v = \lambda \cdot v$ $\checkmark$ بردار ویژه ماتریس مربعی A است، اگر ثابت λ وجود داشته باشد به طوری که:

$$A = \begin{bmatrix} 2 & 3 \\ 2 & 1 \end{bmatrix}_{2 \times 2} \quad v = \begin{bmatrix} 3 \\ 2 \end{bmatrix} \quad A \cdot v = \begin{bmatrix} 2 & 3 \\ 2 & 1 \end{bmatrix} \begin{bmatrix} 3 \\ 2 \end{bmatrix} = \begin{bmatrix} 12 \\ 8 \end{bmatrix} = \underbrace{4}_{\lambda} \underbrace{\begin{bmatrix} 3 \\ 2 \end{bmatrix}}_{v}$$

$$A.v = \lambda.v$$

حاسبی مقدار ویژه یا λ :

$$\hookrightarrow A.v - \lambda I.v = 0 \Rightarrow (A - \lambda.I).v = 0$$

اگر ریشه های دترمینان $(A - \lambda.I)$ را به دست آوریم، مقدار λ به دست می آید.

$$|A - \lambda I| = 0$$

ex: $A = \begin{bmatrix} 0 & 1 \\ -2 & -3 \end{bmatrix}$ $v, \lambda = ?$

$$A.v = \lambda.v \rightsquigarrow \begin{bmatrix} 0 & 1 \\ -2 & -3 \end{bmatrix} - \lambda \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} = \begin{bmatrix} 0 & 1 \\ -2 & -3 \end{bmatrix} - \begin{bmatrix} \lambda & 0 \\ 0 & \lambda \end{bmatrix} = \begin{bmatrix} -\lambda & 1 \\ -2 & -3-\lambda \end{bmatrix}$$

$$|A - \lambda I| = 0$$

$$\begin{vmatrix} -\lambda & 1 \\ -2 & -3-\lambda \end{vmatrix} = -\lambda(-3-\lambda) - (-2) = +3\lambda + \lambda^2 + 2 = 0$$

$$\begin{cases} \lambda_1 = -1 \\ \lambda_2 = -2 \end{cases}$$

فرض: $v_1 = \begin{bmatrix} x \\ y \end{bmatrix}$ $A.v = \lambda.v \xrightarrow{\lambda_1, v_1} A.v_1 = \lambda_1.v_1 \Rightarrow \underset{A}{\begin{bmatrix} 0 & 1 \\ -2 & -3 \end{bmatrix}} \underset{v_1}{\begin{bmatrix} x \\ y \end{bmatrix}} = \underset{v_1}{\begin{pmatrix} -1 \\ \lambda_1 \end{pmatrix} \begin{bmatrix} x \\ y \end{bmatrix}}$

$$\Rightarrow \begin{bmatrix} y \\ -2x-3y \end{bmatrix} = \begin{bmatrix} -x \\ -y \end{bmatrix} \Rightarrow \begin{bmatrix} y \\ -2x-3y \end{bmatrix} - \begin{bmatrix} -x \\ -y \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix} \Rightarrow \begin{cases} y - (-x) = 0 \\ -2x - 3y - (-y) = 0 \end{cases} \rightsquigarrow y = -x$$

$$v_1 = \begin{bmatrix} x \\ y \end{bmatrix} = \begin{bmatrix} x \\ -x \end{bmatrix} \Rightarrow v_1 = x \begin{bmatrix} 1 \\ -1 \end{bmatrix} \rightsquigarrow \text{به ازای تمام } x \text{ ثابت قرار است}$$

$$A \cdot v_2 = \lambda_2 v_2 \quad \text{و} \quad \lambda_2 = -2 \quad v_2 = \begin{bmatrix} m \\ n \end{bmatrix}$$

$$\begin{bmatrix} 0 & 1 \\ -2 & -3 \end{bmatrix} \begin{bmatrix} m \\ n \end{bmatrix} = -2 \begin{bmatrix} m \\ n \end{bmatrix} \Rightarrow \begin{bmatrix} n \\ -2m-3n \end{bmatrix} + 2 \begin{bmatrix} m \\ n \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}$$

$$\Rightarrow \begin{bmatrix} n+2m \\ -2m-3n \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix} \Rightarrow \begin{cases} n+2m=0 \\ -2m-3n=0 \end{cases} \Rightarrow n = -2m \quad v_2 = \begin{bmatrix} m \\ n \end{bmatrix} = \begin{bmatrix} m \\ -2m \end{bmatrix} \Rightarrow v_2 = m \begin{bmatrix} 1 \\ -2 \end{bmatrix}$$

مقادیر منفرد (تکین) ماتریس:

مقادیر منفرد ماتریس $A_{m \times n}$ برابر است با جذر مقادیر ویژه ماتریس AA^T یا $A^T A$:

$$A = \begin{bmatrix} 3 & 1 & 1 \\ -1 & 3 & 1 \end{bmatrix} \quad AA^T = \begin{bmatrix} 3 & 1 & 1 \\ -1 & 3 & 1 \end{bmatrix} \begin{bmatrix} 3 & -1 \\ 1 & 3 \\ 1 & 1 \end{bmatrix} = \begin{bmatrix} 11 & 1 \\ 1 & 11 \end{bmatrix} \quad (*)$$

برای پیدا کردن مقادیر ویژه کافیست یک λ از قطر اصلی ماتریس $(*)$ کم کنیم و دترمینان ماتریس حاصل را محاسبه کنیم:

$$\begin{vmatrix} 11-\lambda & 1 \\ 1 & 11-\lambda \end{vmatrix} = 0 \Rightarrow (11-\lambda)(11-\lambda) - 1 = 0 \Rightarrow (11-\lambda)^2 = 1 \Rightarrow (11-\lambda) = \pm 1$$

$$\Rightarrow 11-\lambda = 1 \Rightarrow \lambda_1 = 10 \quad \text{و} \quad 11-\lambda = -1 \Rightarrow \lambda_2 = 12$$

$$\text{مقادیر تکین} \rightsquigarrow \sqrt{\lambda} \Rightarrow \sigma_1 = \sqrt{10} \quad \text{و} \quad \sigma_2 = \sqrt{12}$$

SVD (Singular Value Decomposition)

تجزیه مقدارهای منفرد ←

$$X = U S V^T$$

← متعامد قطری ← متعامد

$$* \text{متعامد} \rightarrow A \cdot A^T = A^T A = I$$

بررسی روش SVD:

$$X = U S V^T$$

① $X^T X$ را به دست آورید.

$$X = \begin{bmatrix} m & p \\ n & q \end{bmatrix}_{2 \times 2} \begin{bmatrix} \sigma_1 & 0 \\ 0 & \sigma_2 \end{bmatrix}_{2 \times 2} \begin{bmatrix} a & b \\ c & d \end{bmatrix}_{2 \times 2}$$

قطری

② λ را به دست آورید.

③ مقدارهای تکین را به دست آورید و در ماتریس S قرار دهید.

④ V را به دست آورید.

⑤ U را به دست آورید. ← $X V_1 = \sigma_1 U_1$

ex: $X = \begin{bmatrix} 2 & 2 \\ -1 & 1 \end{bmatrix}$

$$X = USV^T$$

$$U = \begin{bmatrix} 0 & 1 \\ 1 & 0 \end{bmatrix} \quad S = \begin{bmatrix} \sqrt{2} & 0 \\ 0 & \sqrt{8} \end{bmatrix} \quad V = \begin{bmatrix} -\frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \end{bmatrix}$$

$$X^T X$$

$$\textcircled{1} X^T X = \begin{bmatrix} 2 & -1 \\ 2 & 1 \end{bmatrix} \begin{bmatrix} 2 & 2 \\ -1 & 1 \end{bmatrix} = \begin{bmatrix} 5 & 3 \\ 3 & 5 \end{bmatrix}$$

$$\textcircled{2} \lambda \rightarrow \begin{vmatrix} 5-\lambda & 3 \\ 3 & 5-\lambda \end{vmatrix} = 0 \Rightarrow (5-\lambda)^2 - 9 = 0 \Rightarrow 5-\lambda = \pm 3 \Rightarrow \lambda_1 = 2 \rightsquigarrow \sigma_1 = \sqrt{2}$$

$$\lambda_2 = 8 \rightsquigarrow \sigma_2 = \sqrt{8}$$

$$\hookrightarrow S = \begin{bmatrix} \sqrt{2} & 0 \\ 0 & \sqrt{8} \end{bmatrix}$$

$$\textcircled{4} \lambda_1 = 2 \rightsquigarrow v_1 = \begin{bmatrix} -\frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} \end{bmatrix} \quad \lambda_2 = 8 \rightsquigarrow v_2 = \begin{bmatrix} \frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} \end{bmatrix}$$

$$\textcircled{5} U \rightsquigarrow X v_1 = \sigma_1 u_1 \Rightarrow \begin{bmatrix} 2 & 2 \\ -1 & 1 \end{bmatrix} \begin{bmatrix} -\frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} \end{bmatrix} = \sqrt{2} \begin{bmatrix} a \\ b \end{bmatrix} \Rightarrow a=0, b=1 \Rightarrow u_1 = \begin{bmatrix} 0 \\ 1 \end{bmatrix}$$

$$X v_2 = \sigma_2 u_2 \Rightarrow \begin{bmatrix} 2 & 2 \\ -1 & 1 \end{bmatrix} \begin{bmatrix} \frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} \end{bmatrix} = \sqrt{8} \begin{bmatrix} c \\ d \end{bmatrix} \Rightarrow c=1, d=0 \Rightarrow u_2 = \begin{bmatrix} 1 \\ 0 \end{bmatrix}$$

تقلیل ابعاد:

کاربردها ← 1. Data Visualization ← برای ترسیم داده ها در 2 یا 3 بعد

← 2. Data Compression ← برای تسریع الگوریتم ها

1. استخراج ویژگی ← Feature Extraction ← 1. تبدیل خطی یا غیر خطی بر روی فضای ویژگی 2. ایجاد ویژگی های جدید از ویژگی های اصلی

$$\begin{bmatrix} x_1 \\ \vdots \\ x_d \end{bmatrix} \rightarrow \begin{bmatrix} y_1 \\ \vdots \\ y_{d'} \end{bmatrix} = f \left(\begin{bmatrix} x_1 \\ \vdots \\ x_d \end{bmatrix} \right)$$

2. انتخاب ویژگی ← Feature Selection

$$\begin{bmatrix} x_1 \\ \vdots \\ x_d \end{bmatrix} \rightarrow \begin{bmatrix} x_{i_1} \\ \vdots \\ x_{i_{d'}} \end{bmatrix} \quad d' < d$$

$$\begin{bmatrix} x_1 \\ \vdots \\ x_{100} \end{bmatrix} \xrightarrow{FS} \begin{bmatrix} x_2 \\ x_5 \\ x_{90} \end{bmatrix} \quad \begin{matrix} d=100 \\ d'=3 \end{matrix}$$

$$\begin{bmatrix} x_1 \\ \vdots \\ x_{100} \end{bmatrix} \xrightarrow{FE} \begin{bmatrix} y_1 \\ y_2 \\ y_3 \end{bmatrix} \quad y_1 = x_2 + 6x_{70}$$

الگوریتم‌های Feature Selection:


PCA ← Unsupervised

به ما یک خط می‌دهد که زمانی داده‌ها روی آن Project یا تصویر می‌شوند بیشترین واریانس را حفظ می‌کنند.

LDA ← Supervised


به ما یک خط می‌دهد که زمانی داده‌ها روی آن Project یا تصویر می‌شوند، داده‌های دو کلاس متفاوت از هم فاصله دارند و داده‌های

هر کلاس به هم نزدیک هستند.



PCA ← در اصل خطی را می یابد که داده ها کمترین فاصله عمودی را با آن داشته باشند.

$$\text{minimize} \rightarrow d_1^2 + d_2^2 + \dots + d_5^2$$



① محاسبه میانگین:

$$\bar{x}_1 = \frac{1+3+5}{3} = 3$$

$$\bar{x}_2 = \frac{2+4+6}{3} = 4$$

ex:

x_1	x_2
1	2
3	4
5	6

② Centerized

$$\begin{bmatrix} 1-3 & 2-4 \\ 3-3 & 4-4 \\ 5-3 & 6-4 \end{bmatrix}$$

$$\text{③ Cov Matrix} \rightarrow \text{Cov} = \frac{1}{m-1} X^T X = \frac{1}{3-1} \begin{bmatrix} -2 & 0 & 2 \\ -2 & 0 & 2 \end{bmatrix} \begin{bmatrix} -2 & -2 \\ 0 & 0 \\ 2 & 2 \end{bmatrix} = \begin{bmatrix} 4 & 4 \\ 4 & 4 \end{bmatrix}$$

$$\text{④ } \lambda \rightarrow \begin{vmatrix} 4-\lambda & 4 \\ 4 & 4-\lambda \end{vmatrix} = 0 \Rightarrow (4-\lambda) = \pm 4$$


$$\Rightarrow \lambda_1 = 0 \rightarrow v_1 = \begin{bmatrix} 1 \\ 1 \end{bmatrix} \xrightarrow{\text{Norm}} \begin{bmatrix} \frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} \end{bmatrix} = \begin{bmatrix} 0.7 \\ 0.7 \end{bmatrix}$$

$$\Rightarrow \lambda_2 = 8 \rightarrow v_2 = \begin{bmatrix} -1 \\ 1 \end{bmatrix} \xrightarrow{\text{Norm}} \begin{bmatrix} -\frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} \end{bmatrix} = \begin{bmatrix} -0.7 \\ 0.7 \end{bmatrix}$$

$$PC_1 \rightsquigarrow y = mx \Rightarrow y = \frac{0.7}{0.7} x \Rightarrow y = x$$

$$PC_2 \rightsquigarrow y = mx \Rightarrow y = \frac{-0.7}{0.7} x \Rightarrow y = -x$$

داده‌های مرکزی‌شده




کدام PC = ۱؟

PC_1 چون به ما فاصله‌های کمینه (۰) را می‌دهد.

ماتریس Proj

$$P = X \cdot V \rightsquigarrow \begin{bmatrix} -2 & -2 \\ 0 & 0 \\ 2 & 2 \end{bmatrix} \times \begin{bmatrix} 0.7 & -0.7 \\ 0.7 & 0.7 \end{bmatrix} = \begin{bmatrix} -2.8 & 0 \\ 0 & 0 \\ 2.8 & 0 \end{bmatrix}$$

$PC_1 \quad PC_2$



حالا ببینیم که با PC_1 اطلاعات را ذخیره کردیم و خیلی راحت از ۲ بعد به ۱ بعد رسیدیم.

$$1. \mu = \frac{1}{m} \sum_{i=1}^m x^{(i)}$$

الـكـوـريـم PCA :

2. Centered X

$$3. \text{Cov} = \frac{1}{m-1} X^T X$$

4. λ, V

$$5. \lambda = \overset{\text{Sorted}}{[\lambda_1 \dots \lambda_d]}$$

$$V = [v_1, \dots, v_{d'}]$$

$\downarrow \qquad \qquad \downarrow$
first PC d'-th PC

$$6. P = XV$$

PCA به کمک SVD:

$$1. \mu_j = \frac{1}{m} \sum_{i=1}^m x_j^{(i)}$$

$$2. \text{Normalized} \rightsquigarrow x_j^{(i)} - \mu_j$$

3. اگر مقیاس feature ها بسیار متفاوت بود، درمقایسه مقیاس با دانه آفامند شوند.

$$4. \text{Cov Matrix} \rightsquigarrow \Sigma = \frac{1}{m} \sum_{i=1}^n (x^{(i)})(x^{(i)})^T$$

5. محاسبه λ و v با استفاده از روش SVD

	S1	S2	S3	S4
Math	95 ^{+1.0} → 9.5	88 ^{8.8}	93 ^{9.3}	75 ^{7.5}
Art	9	8	10	7

