

Session 15

K-means

Machine Learning | Zahra Amini

Telegram: @zahraamini_ai & Instagram:@zahraamini_ai & LinkedIn: @zahraamini-ai


<https://zil.ink/zahraamini>

Supervised $\rightarrow (x_1, y_1) (x_2, y_2) (x_3, y_3) \dots (x_m, y_m)$

Unsupervised $\leftarrow$ k-Means


Unsupervised $\rightarrow (x_1) (x_2) (x_3) \dots (x_m)$

بهترین کاربرد k-means در Marketing است.



Classification

Supervised



Clustering

Unsupervised

خوشه بندی یا clustering: داده ها عضو خوشه یا cluster هستن که بیشترین شباهت را با هم دارند ولی بین خوشه های مختلف بیشترین تفاوت وجود دارد.


در چند که می دانیم این حالت ایده آل است و ما در تلاش محقق ساختن آنیم.

high intra-clustering similarity $\rightarrow$ Cohesive چسبندگی


شباهت یا چسبندگی درون هر cluster باید زیاد باشد. - فاصله های بین داده ها کم

low inter-cluster similarity $\rightarrow$ distinctive تمایز

تمایز بین cluster های متفاوت باید زیاد باشد. - شباهت خارج cluster ها باید کم باشد.



Partitional clustering



Hierarchical

Partitioning

Clustering

سلسله مراتبی یا Hierarchical

$$X = \{x^{(i)}\}_{i=1}^m$$

Partitional Clustering ← خوشه بندی افزایی


ex: $X = \{x^{(1)}, x^{(2)}, x^{(3)}, x^{(4)}, x^{(5)}\} \rightarrow m=5$

$$C = \{C_1, C_2, \dots, C_k\}$$

$$\checkmark \quad \forall j, C_j \neq \emptyset$$

$$\bigcup_{j=1}^k C_j = X$$

$$C = \{C_1, C_2, C_3\} \rightarrow k=3$$



$$\checkmark \quad \forall i, j, C_i \cap C_j = \emptyset$$

به شرط:

1. داده ها (x) در cluster ها پخش شوند به طوری که هیچ cluster تکی نشود.
2. اجتماع عناصر موجود در cluster ها برابر با X شود.
3. تمام cluster ها دو به دو اشتراک شان تکی نشود.


ex:

$$X = \{2, 3, 4, 10, 11, 12, 20, 25, 30\}$$

$$M = 9 \quad k = 2$$

k -means

①



به صورت زرد 3 و 12 برای مراکز انتخاب می شوند.

1. انتخاب k تا mean (centroid) به صورت زرد.

C_1

$$2, 3, 4$$

C_2


$$10, 11, 12, 20, 25, 30$$

2. reassigned داده ها به cluster ها با توجه به مراکزها.

3. به دست آوردن centroid های جدید با توجه به داده ها ← mean

به دست آوردن مراکز جدید → $C_1 = \frac{2+3+4}{3} = 3$ $C_2 = \frac{10+11+12+20+25+30}{6} = 18$

②



4. تکرار مراحل 2 و 3 تا زمانی که تغییری در cluster ها نداشته باشیم.

C_1

$$2, 3, 4, 10$$

C_2

$$11, 12, 20, 25, 30$$

به دست آوردن مراکز جدید → $C_1 = \frac{2+3+4+10}{4} = 4.75$ $C_2 = \frac{11+12+20+25+30}{5} = 19.6$

③

C_1

$$2, 3, 4, 10, 11, 12$$

C_2

$$20, 25, 30$$

$$C_1 = \frac{2+3+4+10+11+12}{6} = 7 \quad C_2 = \frac{20+25+30}{3} = 25$$

$$\begin{cases} C_1 = 7 \\ C_2 = 25 \end{cases}$$




در cluster ها تغییری نداریم. ← پایان

ex:

k=2
m=4

		x	y
x ⁽¹⁾	A	1	1
x ⁽²⁾	B	2	1
x ⁽³⁾	C	4	3
x ⁽⁴⁾	D	5	4

انتخاب اولیه مراکز
 $\begin{cases} C_1 = A \\ C_2 = B \end{cases}$



$dis(B, A) = \sqrt{(2-1)^2 + (1-1)^2} = 1 \checkmark^{min}$
 $dis(x^2, C_2) = \sqrt{(2-3.6)^2 + (1-2.6)^2} = \sqrt{9.32}$

A B	C D
C ₁	C ₂

$\left. \begin{aligned} dis(C, A) &= \sqrt{(4-1)^2 + (3-1)^2} = \sqrt{11} \\ dis(C, B) &= \sqrt{(4-2)^2 + (3-1)^2} = \sqrt{8} \end{aligned} \right\} \xrightarrow{Min} C_2$

C ₁
A
C ₂
B C D

C₁ = A

C₁ = (1.5, 1)

C₂ = (3.6, 2.6)

$\left. \begin{aligned} dis(D, A) &= \sqrt{(5-1)^2 + (4-1)^2} = \sqrt{25} \\ dis(D, B) &= \sqrt{(5-2)^2 + (4-1)^2} = \sqrt{18} \end{aligned} \right\} \xrightarrow{Min} C_2$

$x = \frac{2+4+5}{3} = 3.6$

C₂ = (4.5, 3.5)

$y = \frac{1+3+4}{3} = 2.6$

پایان ✓

k-means $\rightarrow$ ورودی: $X \rightarrow x^{(1)}, x^{(2)}, x^{(3)}, \dots, x^{(m)}$


خروجی: $C \rightarrow C_1, C_2, C_3, \dots, C_k \in \mathbb{R}$

تایید $\rightarrow C_1, C_2, C_3, \dots, C_k$ to Minimize: $\sum_{i=1}^m \min_{j \in 1, \dots, k} d^2(x^{(i)}, c_j)$

$$\sum_{i=1}^m \min_{j \in 1, \dots, k} d^2(x^{(i)}, c_j) \xrightarrow{\text{فاصله اقلیدسی}} \sum_{i=1}^m \min ||x^{(i)} - c_j||^2$$

$\Rightarrow J(C) = \sum_{j=1}^k \sum_{x^{(i)} \in C_j} ||x^{(i)} - c_j||^2 \rightarrow$ در هر cluster فاصله ی داده ها تا مرکز را محاسبه می کند


۲. ایراد k-means چیست؟



۲: برای رفع مشکل Local Minimum چه کنیم؟

می‌توان مراکز اولیه را داده‌هایی که دور هستند را در نظر بگیریم که اگر outlier باشد آن داده باعث می‌شود در روند الگوریتم آن خوشه رشد

نکند چون اطرافش داده‌ی خاصی وجود ندارد.




حاییت نسبت به انتخاب Centroid ها



: Hierarchical


1. تجزی (Agglomerative) ← پایین به بالا


2. ترکیبی (Divisible) ← بالا به پایین



دندروگرام:









$$dis_{sl}(C_i, C_j) = \min_{x \in C_i, x' \in C_j} dis(x, x')$$



$$dis_{cl}(C_i, C_j) = \max_{x \in C_i, x' \in C_j} dis(x, x')$$



$$dis_{ward}(C_i, C_j) = \frac{|C_i| |C_j|}{|C_i| + |C_j|} dis(C_i, C_j)$$



$$dis_{AvgL} = \frac{1}{|X| \cdot |X'|} \sum_{x \in X} \sum_{x' \in X'} d(x, x')$$

dis

	x	y
A	1	1
B	1.5	1.5
C	5	5
D	3	4
E	4	4
F	3	3.5

	A	B	C	D	E	F
A	○					
B	0.71	○				
C	5.66	4.95	○			
D	3.36	2.92	2.24	○		
E	4.24	3.54	1.41	1	○	
F	3.2	2.5	2.5	<u>0.5</u>	1.12	○

	A	B	C	D	E
A	○				
B	<u>0.71</u>	○			
C	5.66	4.95	○		
D F	3.2	2.5	2.24	○	
E	4.24	3.54	1.41	1	○

	AB	C	DF	E
AB	○			
C	4.95	○		
DF	2.50	2.24	○	
E	3.54	1.41	<u>1</u>	○

	AB	C	DFE
AB	○		
C	4.95	○	
DFE	2.50	1.41	○

	AB	CDEF
AB	○	
CDEF	2.5 <u>u u u</u>	○

