

# Session 16

DBSCAN

**Machine Learning | Zahra Amini**

Telegram: @zahraamini\_ai & Instagram: @zahraamini\_ai & LinkedIn: @zahraamini-ai

<https://zil.ink/zahraamini>

## خوشه بندی مبتنی بر چگالی ← Density-Based Clustering

1. بر اساس چگالی داده ها کار می کند.

2. لازم نیست مقدار  $k$  (تعداد خوشه ها) از ابتدا مشخص باشد.

3. نسبت به نویز و داده پرت مقاوم است.


4. برای تعداد زیاد داده ها مناسب هست.

یکی از معروف ترین الگوریتم های مبتنی بر چگالی (DBSCAN) Density-Based Spatial Clustering of Applications with Noise است.

پارامترهای DBSCAN:

$\epsilon$  ← EPS: ماکزیمم شعاع همسایگی.

$MinPts = 3$



$MinPts$ : حداقل تعداد نقاط در یک همسایگی به شعاع  $\epsilon$ .

تعریف انزاع نقاط:

$$N_{\epsilon}(q) = \{p \text{ belongs to } N \mid \text{dist}(p, q) \leq \epsilon\}$$

1. نقاط همسایه نقطه  $q$  ← Neighbor Points :

$$|N_{\epsilon}(q)| \geq \text{MinPts}$$

2. نقطه هسته‌ای ← Core Point :


3. نقطه حاشیه‌ای ← Border Point : نقطه‌ای که تعداد نقاط همسایه اش در شعاع  $\epsilon$  کمتر از MinPts باشد و به Core Point نزدیک باشد.

4. نقطه نویزی ← Noise Point : نقطه‌ای که نه Core Point و نه Border Point است.

یا outlier


$$\epsilon = 1$$

$$\text{MinPts} = 5$$



## دسترسی مستقیم به چگالی ← Directly density-reachable

نقطه  $q$  به صورت مستقیم density-reachable است به وسیله نقطه  $p$  به شرط اینکه :



MinPts = 4

1.  $q \in N_{\epsilon}(p)$  همسایه  $p$  باشد.


2.  $|N_{\epsilon}(p)| \geq \text{MinPts}$  یک Core Point باشد.

## Density-Reachable

1. نقطه  $p$  به صورت مستقیم density-reachable است از نقطه  $p_2$

2. نقطه  $p_2$  به صورت مستقیم density-reachable است از نقطه  $p_1$

3. نقطه  $p_1$  به صورت مستقیم density-reachable است از نقطه  $q$



MinPts = 7

$q \rightarrow p_1 \rightarrow p_2 \rightarrow p$

-  $p$  is (indirectly) density-reachable from  $q$

-  $q$  is not density-reachable from  $p$



## الگوریتم DBSCAN:

1. یک نقطه  $P$  را انتخاب می‌کنیم که تا به حال  $visit$  نشده (بدون برچسب)

2. و بعد تمام نقاطی که به صورت  $density\text{-}reachable$  هستند نسبت به  $P$  با پارامترهای  $\epsilon$  و  $MinPts$  پیدا می‌کنیم.

3. اگر این نقاط  $Core$  بودند به  $P$  وصل می‌شوند و یک خوشه را تشکیل می‌دهند. ← در غیر این صورت نقاط برچسب  $Border$  یا  $Noise$  می‌خورند.

4. مراحل بالا را آنقدر تکرار می‌کنیم تا بلاخره تمام نقاط برچسب بخورند.

Supervised  $\rightarrow$  Classification  $\rightarrow$

$$\frac{TP + TN}{TP + TN + FP + FN}$$

معیار ارزیابی:


Unsupervised  $\rightarrow$  Clustering  $\rightarrow$

$$\sum_{i=1}^k \sum_{x \in K_i} (x - c_i)^2$$


↪ مرکز خوشه نام


Ex:

| X   | Y   |
|-----|-----|
| 1   | 2   |
| 3   | 4   |
| 2.5 | 4   |
| 1.5 | 2.5 |
| 3   | 5   |
| 2.8 | 4.5 |
| 2.5 | 4.5 |
| 1.2 | 2.5 |
| 1   | 3   |
| 1   | 5   |
| 1   | 2.5 |
| 5   | 6   |
| 4   | 3   |



Data





| X   | Y   | Distance from (1,2) |
|-----|-----|---------------------|
| 1   | 2   | 0                   |
| 3   | 4   | 2.8                 |
| 2.5 | 4   | 2.5                 |
| 1.5 | 2.5 | 0.7                 |
| 3   | 5   | 3.6                 |
| 2.8 | 4.5 | 3.08                |
| 2.5 | 4.5 | 2.9                 |
| 1.2 | 2.5 | 0.53                |
| 1   | 3   | 1                   |
| 1   | 5   | 3                   |
| 1   | 2.5 | 0.5                 |
| 5   | 6   | 5.6                 |
| 4   | 3   | 3.1                 |

| Point      | Neighbourhood Points |            |            |            |           |
|------------|----------------------|------------|------------|------------|-----------|
| (1,2)      | (1.2, 2.5)           |            | (1, 2.5)   |            |           |
| (3, 4)     | (2.5, 4)             |            | (2.8, 4.5) |            |           |
| (2.5, 4)   | (3, 4)               | (2.8, 4.5) | (2.5, 4.5) |            |           |
| (1.5, 2.5) | (1.2, 2.5)           |            | (1, 2.5)   |            |           |
| (3, 5)     | (2.8, 4.5)           |            |            |            |           |
| (2.8, 4.5) | (3, 4)               | (2.5, 4)   | (3, 5)     | (2.5, 4.5) | Cluster 1 |
| (2.5, 4.5) | (2.5, 4)             |            | (2.8, 4.5) |            |           |
| (1.2, 2.5) | (1, 2)               | (1.5, 2.5) | (1, 3)     | (1, 2.5)   | Cluster 2 |
| (1, 3)     | (1.2, 2.5)           |            | (1, 2.5)   |            |           |
| (1, 5)     |                      |            |            |            |           |
| (1, 2.5)   | (1, 2)               | (1.5, 2.5) | (1.2, 2.5) | (1, 3)     | Cluster 2 |
| (5, 6)     |                      |            |            |            |           |
| (4, 3)     |                      |            |            |            |           |

| Point      | Neighbourhood Points |            |            |            |              |           |
|------------|----------------------|------------|------------|------------|--------------|-----------|
| (1,2)      | (1.2, 2.5)           | (1, 2.5)   |            |            | Border Point |           |
| (3, 4)     | (2.5, 4)             | (2.8, 4.5) |            |            | Border Point |           |
| (2.5, 4)   | (3, 4)               | (2.8, 4.5) | (2.5, 4.5) |            | Border Point |           |
| (1.5, 2.5) | (1.2, 2.5)           | (1, 2.5)   |            |            | Border Point |           |
| (3, 5)     | (2.8, 4.5)           |            |            |            | Border Point |           |
| (2.8, 4.5) | (3, 4)               | (2.5, 4)   | (3, 5)     | (2.5, 4.5) | Core Point   | Cluster 1 |
| (2.5, 4.5) | (2.5, 4)             | (2.8, 4.5) |            |            | Border Point |           |
| (1.2, 2.5) | (1, 2)               | (1.5, 2.5) | (1, 3)     | (1, 2.5)   | Core Point   | Cluster 2 |
| (1, 3)     | (1.2, 2.5)           | (1, 2.5)   |            |            | Border Point |           |
| (1, 5)     |                      |            |            |            | Outlier      |           |
| (1, 2.5)   | (1, 2)               | (1.5, 2.5) | (1.2, 2.5) | (1, 3)     | Core Point   | Cluster 2 |
| (5, 6)     |                      |            |            |            | Outlier      |           |
| (4, 3)     |                      |            |            |            | Outlier      |           |



| Cluster 1  | Cluster 2  | Outliers |
|------------|------------|----------|
| (3,4)      | (1, 2)     | (1, 5)   |
| (2.5, 4)   | (1.5, 2.5) | (5, 6)   |
| (3,5)      | (1.2, 2.5) | (4, 3)   |
| (2.8, 4.5) | (1, 3)     |          |
| (2.5, 4.5) | (1, 2.5)   |          |



روشهای تشخیص داده های پرت:

1. Clustering-Based      2. Proximity-Based      3. Classification-Based      4. Statistical

1. Clustering-Based:

داده پرت ← داده ای که فاصله اش تا نزدیکترین خوشه زیاد است.


داده ای که در خوشه کوچک، اسپارس یا کم جمعیت است.

داده ای که به هیچی که ام از خوشه ها متعلق نیست.

۲. مشکل: نمی توانیم از k-means برای پیدا کردن داده پرت استفاده کنیم، چرا؟

چون تمام داده ها را clustering می کند بنابراین داده های پرت را خوشه بندی می کند و برعکس outlier نمی زند، از طرفی برای داده های زیاد دهم مناسب نیست.

← سراغ DBSCAN می رویم.



## 2. Proximity-Based ← مبتنی بر نزدیکی

1. براساس فاصله (Distance): نمونه پرت، نمونه ایست که تعداد همسایه هایش از یک حدی کمتر باشد.

مشکل: عملکرد این روش وابسته به معیار نزدیکی است که انتخاب می شود.

2. براساس چگالی: نمونه پرت نمونه ایست که چگالی اطراف آن از نمونه های دیگر کمتر باشد.

مشکل: تعیین شعاع همسایگی و حداقل تعداد همسایه ها، چالش برانگیز است.

## 3. Classification-Based: در این روش ما برچسب داده ها را داریم. یعنی می دانیم کدام داده ها Normal و کدام داده ها


outlier هستند.

مشکل: تعداد داده های نرمال نسبت به داده های پرت بسیار زیاد است، بنابراین classification بسیار به عمل می کند. → توازن بین کلاسها نیست

ممکن است classifier نتواند داده های پرت جدید را تشخیص دهد. → می توانیم از مدل تک کلاسه SVM استفاده کنیم. → مرز داده ها را با روش SVM


پیدا کنیم، در این صورت داده های پرت خارج از مرز قرار می گیرند.

Boxplot:



© Byjus.com

Histogram:



$$\rightarrow \Sigma = 99.8\% \leq 5,000$$

$$0.2\% > 5,000$$

:Statistical 4


Normal Distribution:

$\mu, \sigma$


outlier  $\rightarrow \mu \pm 3\sigma$

Standard Normal Distribution

$\mu = 0 \mid \sigma = 1$



# کشف موارد غیر متعارف ← Anomaly Detection ← Unsupervised



1. انتخاب ویژگی‌هایی که میزان وقوع غیر متعارف آنها نشان دهنده موارد غیر عادی است.

2. محاسبه  $\mu$  و  $\sigma$  هر ویژگی مجموعه train

$$\mu_j = \frac{1}{m} \sum_{i=1}^m x_j^{(i)}$$

$$\sigma_j^2 = \frac{1}{m} \sum_{i=1}^m (x_j^{(i)} - \mu_j)^2$$


3. بررسی غیر عادی بودن هر نمونه با محاسبه  $P(x)$ .

$$P(x) = \prod_{j=1}^n P(x_j; \mu_j, \sigma_j^2) = \prod_{j=1}^n \frac{1}{\sigma_j \sqrt{2\pi}} \exp\left(-\frac{(x_j - \mu_j)^2}{2\sigma_j^2}\right)$$

\* اگر  $P(x) < \epsilon$  آنگاه  $x$  یک نمونه غیر عادی (outlier) است.

ex:  $x_1 = 12$ ,  $x_2 = -1$

$$P(x) = P(x_1; \mu_1, \sigma_1^2) P(x_2; \mu_2, \sigma_2^2) =$$



$$P(12, 5, 2^2) \times P(-1, 3, 1^2) = \left( \frac{1}{2\sqrt{2\pi}} e^{-\frac{(12-5)^2}{2 \times 2^2}} \right) \times$$

$$\left( \frac{1}{2\sqrt{2\pi}} e^{-\frac{(-1-3)^2}{2 \times 1^2}} \right) = \bigcirc$$

